

PRESENTASI SKRIPSI

PENERAPAN METODE AUTOENCODER UNTUK REKONSTRUKSI DAN KOMPRESI CITRA DIGIT TULISAN TANGAN MENGGUNAKAN DATASET MNIST

Oleh: Khaerul Akbar

NIM: 24260034

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK DAN ILMU KOMPUTER

UNIVERSITAS NAHDLATUL ULAMA INDONESIA | JAKARTA 2024

Latar Belakang Penelitian

Urgensi Kompresi Citra

Perkembangan kecerdasan buatan, khususnya *Deep Learning*, telah merevolusi cara manusia memproses data visual. Seiring dengan peningkatan penyimpanan dan transmisi data citra skala besar, efisiensi kompresi menjadi aspek yang sangat relevan.

- ✓ **Non-Linear Feature Extraction:** Autoencoder mampu mempelajari representasi fitur non-linear yang lebih kompleks dibanding metode linier seperti PCA.
- ✓ **Bottleneck Representation:** Memadatkan data ke dalam dimensi rendah (latent space) tanpa kehilangan informasi krusial.
- ✓ **MNIST Dataset:** Digunakan sebagai standar benchmark pengujian model reduksi dimensi.

Sampel Dataset MNIST

Sampel visualisasi citra grayscale digit tulisan tangan dari Dataset MNIST (28x28 piksel).

Fokus & Batasan Penelitian

⚠ Rumusan Masalah

Bagaimana performa kompresi-rekonstruksi Autoencoder pada MNIST?

Bagaimana membangun model *Fully Connected Autoencoder* yang optimal untuk citra digit tulisan tangan?

Bagaimana tingkat degradasi kualitas rekonstruksi citra akibat variasi dimensi *latent space* (8, 32, 64, 128)?

Bagaimana visualisasi struktur *latent space* dipetakan menggunakan t-SNE?

🔧 Batasan Masalah

Eksperimen dibatasi pada parameter berikut:

Dataset yang digunakan bersumber dari `mnist_train.csv` (60.000 sampel).

Model arsitektur bertipe *fully connected Dense Autoencoder*.

Implementasi menggunakan Python & framework **PyTorch**.

Pelatihan dengan Optimizer **Adam**, loss function **MSE**, selama 20 epoch.

Evaluasi metrik dibatasi pada: MSE, RMSE, MAE, dan PSNR.

Tujuan & Manfaat Penelitian



Tujuan Utama

Mengimplementasikan model Autoencoder menggunakan PyTorch dengan evaluasi sistematis pada 20 epoch pelatihan untuk meminimalisir rekonstruksi loss.



Analisis Dimensi

Menganalisis pengaruh kompresi secara kuantitatif melalui variasi dimensi bottleneck (8, 32, 64, 128) untuk mengukur rasio trade-off antara ukuran kompresi dan kualitas visual.



Manfaat Akademik

Menjadi referensi akademik yang komprehensif bagi mahasiswa teknik informatika dalam mempelajari konsep representasi fitur unsupervised learning.



Manfaat Industri

Memberikan fondasi awal pengembangan arsitektur kompresi cerdas untuk efisiensi penyimpanan cloud, transmisi data IoT, atau OCR tulisan tangan.

Penelitian Terdahulu & Orisinalitas

Peneliti & Referensi	Fokus & Metode	Kekurangan / Gap	Usulan Kebaharuan
Hinton & Salakhutdinov (2006)	Deep Autoencoder untuk reduksi dimensi, dibandingkan dengan metode PCA klasik.	Tidak ada visualisasi latent space yang mendalam.	Kombinasi analisis komparatif variasi dimensi latent space (8 hingga 128) yang dievaluasi dengan t-SNE 2D mapping dan metrik lengkap (PSNR, MAE, MSE, RMSE).
Vincent et al. (2010)	Stacked Denoising Autoencoder untuk mengembalikan citra dari noise kotor.	Fokus pada robustness noise, bukan pada trade-off kompresi.	
Tschannen et al. (2018)	Kajian teori representasi learning modern (VAE, WAE, dll).	Dominan bersifat survei teoritis tanpa pengujian empiris kuantitatif langsung.	
Bank et al. (2023)	Studi varian Autoencoder (Sparse, Contractive, dll) lintas domain.	Tidak membahas dampak spesifik ukuran dimensi latent space pada rekonstruksi MNIST.	

Arsitektur Autoencoder

Metode Unsupervised Learning

Arsitektur model dirancang secara simetris antara **Encoder** (pembatas dimensi) dan **Decoder** (rekonstruktor citra).

Encoder (784 → 256 → 128 → 64 → 32): Berfungsi memadatkan input dimensi tinggi (vektor 784 piksel dari 28x28) menjadi representasi laten berdimensi rendah (32). Menggunakan aktivasi ReLU.

Decoder (32 → 64 → 128 → 256 → 784): Merekonstruksi kembali dari representasi laten menjadi citra keluaran yang semirip mungkin dengan input asli. Menggunakan aktivasi Sigmoid di lapisan output.

Dataset MNIST & Metrik Evaluasi

Karakteristik Dataset

Total Sampel	70.000 citra grayscale
Data Latih / Uji	60.000 / 10.000 sampel
Dimensi Citra	28 x 28 piksel (1 channel)
Nilai Piksel	Integer 0-255 (dinormalisasi ke [0,1])
Jumlah Kelas	10 kelas (digit 0 - 9, seimbang)

Metrik Kuantitatif Kunci

Mean Squared Error (MSE):

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2$$

Peak Signal-to-Noise Ratio (PSNR):

$$PSNR = 10 \times \log_{10} \frac{MAX^2}{MSE}$$

Metodologi & Kerangka Berpikir



1. Akuisisi Data

Mengunduh dataset MNIST berekstensi CSV dan mempersiapkan lingkungan PyTorch.



2. Pra-pemrosesan

Normalisasi piksel dari 0-255 ke rentang $[0,1]$, memisahkan label, dan konversi ke Tensor.



3. Pemodelan & Pelatihan

Penyusunan arsitektur encoder-decoder, pelatihan 20 epoch dengan optimizer Adam.



4. Evaluasi & Visualisasi

Perhitungan metrik error (MSE, PSNR), reduksi dimensi t-SNE untuk analisis latent space.

| Implementasi & Parameter Pelatihan

32

LATENT DIMENSION

Konfigurasi Eksperimen

Model dibangun dengan arsitektur PyTorch yang dioptimalkan untuk performa tinggi pada CPU/GPU, berfokus pada kestabilan konvergensi loss.

⚙️ Hyperparameter

Learning Rate: 0.001 (1e-3)

Batch Size: 256

Optimizer: Adam Optimizer

Loss: Mean Squared Error

🧠 Spesifikasi Kelas

Epochs: 20 Epochs

Input Layer: 784 neuron

Aktivasi Layer Tersembunyi: ReLU

Aktivasi Layer Output: Sigmoid

Hasil Eksperimen Variasi Latent Space

Analisis Kuantitatif Trade-off Kompresi


Eksperimen variasi dimensi latent space menunjukkan pengaruh langsung dimensi kompresi terhadap kemampuan model mempertahankan detail informasi citra.

Dimensi Latent Space	Rasio Kompresi (%)	Mean Squared Error (MSE)	Root Mean Squared Error (RMSE)	Mean Absolute Error (MAE)	Peak Signal-to-Noise Ratio (PSNR)
8 (Sangat Padat)	98.98%	0.0384	0.1959	0.1241	14.15 dB (Kualitas Kurang)
32 (Optimal)	95.91%	0.0143	0.1195	0.0682	18.44 dB (Cukup Baik)
64 (Medium)	91.83%	0.0089	0.0943	0.0412	20.50 dB (Sangat Baik)
128 (Rendah)	83.67%	0.0051	0.0714	0.0245	22.92 dB (Sangat Baik)

**Dimensi latent space 32 dipilih sebagai konfigurasi terbaik (sweet spot) karena mencapai rasio kompresi 95.91% dengan degradasi visual minimum.*


Analisis Kualitatif & Representasi Laten

Hasil Rekonstruksi Citra



Perbandingan baris: Citra Asli vs Rekonstruksi Autoencoder (dimensi laten 32) vs Heatmap Selisih Error.

Klasterisasi Ruang Laten t-SNE



Visualisasi pemetaan t-SNE dari 3.000 sampel uji. Digit yang serupa berhasil diklasterkan bersama secara unsupervised.

| Kesimpulan & Saran

Kesimpulan

Autoencoder berhasil diterapkan untuk rekonstruksi dan kompresi citra digital digit MNIST secara unsupervised.

Konfigurasi pelatihan menggunakan optimizer Adam & MSE loss menghasilkan pelatihan yang stabil dengan titik konvergensi konstan pada 20 epoch.

Model dengan dimensi laten 32 mampu melakukan kompresi data hingga 95.91% dari ukuran file original namun tetap mempertahankan struktur utama digit.

Saran Pengembangan

Mengeksplorasi penggunaan arsitektur *Convolutional Autoencoder (CAE)* untuk memelihara korelasi spasial citra yang lebih presisi.


Menggunakan loss function berbasis persepsi visual seperti SSIM (Structural Similarity Index Measure) sebagai alternatif MSE.

Menguji model dengan dataset dengan tingkat kompleksitas variasi objek lebih tinggi, seperti Fashion-MNIST atau CIFAR-10.

Terima Kasih Atas Perhatian Anda


Sesi Tanya Jawab (Q&A)

Image Sources




https://upload.wikimedia.org/wikipedia/commons/thumb/b/b1/MNIST_dataset_example.png/330px-MNIST_dataset_example.png

Source: en.wikipedia.org




<https://programmingoceanacademy.s3.ap-southeast-1.amazonaws.com/ai-architectre/autoencoder-architecture.png>

Source: www.programming-ocean.com



https://towardsdatascience.com/wp-content/uploads/2022/08/1OU19y3l5u1lXmCNKI6_5JA.png

Source: towardsdatascience.com



<https://media.geeksforgeeks.org/wp-content/uploads/20240916170923/latent-space-t-SNE.jpg>

Source: www.geeksforgeeks.org